

Actividad Clase 2 - 10/3

Grupo 2: Amazon (Justo Valente, Joaquin Gelves, Augusto Diaz de Valdes, Simon Godino, Benjamin Alonso y Simon Lawson)

1. Las 5 V's del Big Data en Amazon

- **Volumen:** Amazon maneja cantidades masivas de información que escalan de petabytes a exabytes. Estos datos incluyen miles de millones de transacciones comerciales, historiales de búsqueda, reseñas, y mucho más.
- **Velocidad:** El procesamiento se realiza tanto por lotes (batch) para análisis históricos, como en tiempo real (streaming) para los sistemas de recomendación de productos y demás, bien personalizado.
- **Variedad:** Amazon utiliza datos estructurados (transacciones bancarias, perfiles de clientes), semi-estructurados (registros de navegación o *logs*) y no estructurados (reseñas de texto libre, imágenes de productos y videos).
- **Veracidad:** El desafío está en la fiabilidad de los datos, como filtrar reseñas falsas o inconsistencias en los datos de navegación, ya que uno de cada tres líderes de negocio no confía plenamente en la información que usa para decidir.
- **Valor:** El beneficio principal es la ventaja competitiva; por ejemplo, su personalización mediante información guardada y procesada es clave para diferenciarse.

2. Almacenamiento

- **Arquitectura de Almacenamiento:** Es probable que Amazon utilice un enfoque de Data Lake o Data Lakehouse por su heterogeneidad de datos que necesitan procesar,
- **Desafíos de Escalabilidad y Costo:** El almacenamiento de exabytes es costoso, por lo que Amazon migra de un modelo de Capex (inversión en hardware físico) a uno de Opex (gasto operativo en la nube), lo que permite que el almacenamiento crezca de forma elástica según la demanda sin inversiones iniciales masivas.

3. Procesamiento y Análisis

- **Tipo de Procesamiento:** Amazon requiere de ambos. El procesamiento por lotes sirve para predicciones de inventario a largo plazo, mientras que el procesamiento en streaming (como Apache Spark o Storm) es vital para reaccionar a los clics del usuario en tiempo real.
- **Herramientas de Análisis:**
 - **SQL:** Para consultar datos estructurados en sus almacenes de datos.
 - **Python:** Debido a su amplia variedad de bibliotecas (Pandas, por ejemplo) para limpieza y modelado.
 - **Machine Learning:** Especialmente algoritmos de sistemas de recomendación y aprendizaje supervisado (clasificación) para predecir qué productos le interesarán al cliente

4. Gobernanza y Seguridad

- **Datos Sensibles:** Amazon maneja datos personales críticos como nombres, direcciones, historiales de navegación y datos de tarjetas de crédito.
- **Desafíos de Seguridad y Privacidad:** Debe cumplir con marcos legales estrictos como el RGPD (GDPR), asegurando la minimización de datos y la protección contra accesos no autorizados. El principal riesgo es el uso de datos sin consentimiento (como el caso de Cambridge Analytica) y la filtración de información a través de dispositivos personales en entornos corporativos (BYOD).

Resumen del análisis

1. Oportunidad de Negocio Amazon utiliza el Big Data con un doble propósito: hiperpersonalizar la experiencia de compra del usuario y optimizar toda su cadena de suministro y logística.

2. El Ecosistema de Datos (Las 5 V's): Capturan un Volumen gigantesco de información de gran Variedad (clics, historial de compras, carritos abandonados y datos de sensores en camiones). Todo esto se procesa a gran velocidad para hacer recomendaciones en tiempo real y, tras asegurar la Veracidad de la información, se convierte en un inmenso Valor económico para la empresa.

3. Infraestructura y Tecnología (Almacenamiento y Procesamiento): Debido a la escala global, no pueden usar bases de datos tradicionales. Requieren sistemas distribuidos y escalables que soportan procesamiento híbrido:

- En streaming (tiempo real): Para el motor de recomendaciones ("clientes que compraron esto también compraron...").
- Por lotes (batch) + Machine Learning: Para analizar datos históricos y predecir qué inventario se necesitará en cada región.

4. Riesgos y Cuidados (Gobernanza y Seguridad): El principal punto crítico es la custodia de datos financieros y personales altamente sensibles (tarjetas, direcciones, gustos personales). El éxito del modelo depende de evitar fraudes informáticos y ofrecer personalización sin invadir la privacidad del usuario.

Impacto Final: El análisis de grandes volúmenes de datos le permite a Amazon adelantarse al cliente: le vende más porque le sugiere exactamente lo que busca y gasta menos en logística porque mueve el producto al almacén más cercano antes de que se produzca la venta.