

Guía de Práctica: Introducción a BigQuery

Objetivo: Comprender cómo funciona un Data Warehouse moderno procesando datos públicos y propios a gran escala.

1. ¿Qué estamos haciendo realmente?

En esta práctica, vas a utilizar **BigQuery**. A diferencia de una base de datos tradicional (como MySQL), BigQuery es un **Data Warehouse** basado en la nube.

- **No hay servidores:** No instalas nada. Google pone miles de CPUs a trabajar para ti.
- **Escalabilidad:** Puede analizar Terabytes de datos en segundos.
- **Separación de datos:** Aprenderás la diferencia entre usar datos que otros comparten (Public Datasets) y subir tus propios datos.

2. Fase 1: Explorar un "Data Lake" Público (Tareas 1 y 2)

BigQuery aloja cientos de datasets gratuitos. Esto simula un escenario real donde tu empresa consume datos externos (clima, censos, tendencias) para enriquecer su propia información.

- **¿Qué aprenderás?** A conectar BigQuery con fuentes de datos externas y usar SQL para extraer valor inmediato.
- **Concepto clave: Procesamiento Distribuido.** Cuando ejecutas el **SELECT**, BigQuery escanea millones de filas de nombres de bebés en segundos usando la infraestructura masiva de Google.

3. Fase 2: Crear tu propia infraestructura (Tareas 3, 4 y 5)

Aquí dejas de ser un espectador y te conviertes en un **Data Engineer**. Vas a simular la ingesta de datos (Ingestion).

- **El archivo (**yob2014.txt**):** Es un archivo **CSV** (texto plano). En el mundo real, esto podría ser un log de ventas o registros de sensores.
- **El Dataset (**babynames**):** Piensa en el Dataset como una **carpeta o contenedor**. Es donde organizas tus tablas y defines quién tiene permiso para verlas.
- **El Esquema (**Schema**):** Es la estructura. Le dices a BigQuery: "La primera columna es texto (nombre), la segunda es texto (género) y la tercera es un número (conteo)". Sin

esquema, los datos son solo texto sin sentido.

4. Fase 3: Análisis y Resultados (Tarea 6)

Una vez que los datos están "limpios" y cargados en tu tabla, ejecutas una consulta final.

- **¿Qué aprenderás?** A cruzar criterios (filtros como `WHERE gender = 'M'`) y ordenar resultados para obtener **insights** (información accionable).
- **Diferencia clave:** Verás que la sintaxis para consultar tu propia tabla es casi idéntica a la de los datos públicos; lo único que cambia es la "ruta" del archivo.

EJERCICIOS

? Preguntas de Comprensión

1. Sobre la primera consulta (Los nombres públicos)

Pregunta: En la Tarea 2, ejecutaste una consulta sobre millones de registros de nombres en EE.UU. ¿Qué fue lo que "hizo" realmente esa instrucción de texto (la query) con toda esa montaña de datos?

- **A.** Copió todos los datos a tu computadora para que los pudieras ver.
- **B.** Le pidió a los servidores de Google que buscaran, sumaran y ordenaran los datos allá en la nube, entregándote solo el "top 10" final.
- **C.** Borró los nombres menos comunes para que la tabla fuera más pequeña.

2. Sobre la carga de datos (El archivo de 2014)

Pregunta: En la Tarea 5, subiste un archivo de texto (`yob2014.txt`) y creaste una tabla. ¿Por qué es necesario este paso antes de poder hacer preguntas (queries) a los datos?

Respuesta: Es necesario cargar el archivo antes porque BigQuery debe convertir ese archivo de texto en una tabla estructurada con un esquema definido. De esta manera puede reconocer qué representa cada columna, por ejemplo el nombre, el género y la cantidad. Sin este paso, el archivo sería solo texto plano y no podría ser consultado mediante SQL.

3. Sobre la diferencia entre lo "Público" y lo "Propio"

Pregunta: Hiciste consultas sobre un dataset de Google ([bigquery-public-data](#)) y sobre uno que creaste tú ([babynames](#)). ¿Cuál es la principal ventaja de tener ambos mundos en la misma herramienta?

Respuesta : La principal ventaja de tener datos públicos y datos propios en la misma herramienta es que permite combinar información externa con la información interna de la empresa en un solo lugar. Esto facilita hacer análisis más completos, encontrar patrones y tomar mejores decisiones. Por ejemplo, se pueden relacionar datos públicos de tendencias o mercado con datos propios de ventas para obtener insights más valiosos.

El Desafío Rápido

En la última tarea, la query les trajo los nombres de hombres más populares. Si quisieran saber cuáles fueron los 20 nombres de **mujeres** más usados en 2014, ¿Cómo sería la query (consulta SQL)?

```
SELECT name, number
FROM `tu_proyecto.babynames.names_2014`
WHERE gender = 'F'
ORDER BY number DESC
LIMIT 20;
```

Link al Laboratorio:

https://www.cloudskillsboost.google/focuses/3616?catalog_rank=%7B%22rank%22%3A8%2C%22num_filters%22%3A1%2C%22has_search%22%3Atrue%7D&parent=catalog&search_id=52306923