

Detección de Gastos Sospechosos en Rendiciones Corporativas

Grupo:*DataLab*

Modelado predictivo con Orange Data Mining → optimizar el control de rendiciones en ConexaServicios.

Materia: Big Data

Benjamín Alonso · Joaquín Gelves · Simón Godino Ferrando · Simón Lawson · Augusto Díaz de Valdés · Justo Valente

02 de junio de 2026

Problema de Negocio

El control de rendiciones es hoy un proceso manual, costoso y con riesgo de error.



Contexto

Auditoría revisa el 100% de las rendiciones de gastos, una por una.



Problema

Proceso lento y caro; la fatiga del revisor deja pasar casos sospechosos.



Objetivo

Modelo de clasificación binaria que prediga si una rendición es sospechosa.



Pregunta de negocio

¿Podemos priorizar la cola y revisar solo lo de mayor riesgo?

100%

de las rendiciones se revisan
hoy de forma manual

Dataset

15.000

registros

22


variables

32%

sospechosas

- Variable objetivo: gasto_sospechoso (binaria: 0 legítimo / 1 sospechoso).
- 22 variables predictoras: monetarias, temporales, categóricas, del empleado y de control.
- Identificadores sin valor predictivo, excluidos del modelo.
- Desbalance moderado de clases: 68% legítimos frente a 32% sospechosos.

Distribución de clases



■ Legítimos (68%) ■ Sospechosos (32%)

Calidad de Datos

Problemas encontrados

- tipo_comprobante con 18 variantes por mayúsculas y abreviaturas.
- hora_carga_sistema con ~8% de valores nulos.
- proveedor_en_lista_aprobada con ~3% de valores nulos.

Soluciones implementadas

- Unificación a 4 categorías canónicas (Edit Domain).
- Imputación por media en la variable horaria.
- Nulos de proveedor preservados como categoría 'Sin_dato'.

Antes / Después

Aspecto	Antes	Después
tipo_comprobante	18 variantes	4 categorías
hora_carga_sistema	~8% nulos	imputada
proveedor_aprobado	~3% nulos	'Sin_dato'

EDA - Hipótesis de Negocio



Desvío del histórico

El gasto sospechoso se aparta del monto habitual del propio empleado.



Violación de control

Excede el límite de política y se asocia a proveedores no aprobados.





Patrón temporal

Se concentra en horarios inusuales, demoras o fines de semana.

EDA - Hipótesis de Negocio

- Monto: mediana sospechosa \$65.706 vs. legítima \$38.300 ($t = 32$; $p \approx 0$).
- El histórico aislado no discrimina ($t = 0,34$): la señal está en la relación.
- Por encima del límite de política predominan los casos sospechosos.
- Proveedor no aprobado: 46% de fraude vs. 27% si está aprobado (base 32%).
- Variables temporales sin poder discriminativo relevante.



Conclusiones del EDA



H1 — Confirmada

El desvío respecto del histórico es predictivo, capturado mediante un ratio.



H2 — Confirmada

La violación de política y el proveedor no aprobado son señales potentes.



H3 — Refutada

El comportamiento temporal no aporta capacidad discriminativa.

Qué aprendimos

La señal de fraude se concentra en variables monetarias relacionales y de control interno.

Ni el tiempo ni la jerarquía del empleado aportan valor predictivo.

Preprocesamiento



Limpieza (Edit Domain)

Categorías inconsistentes unificadas a valores canónicos.



Codificación (Continueize)

One-Hot para nominales; ordinales pre-mapeadas; numéricas sin cambio.



Selección (Select Columns)

Roles definidos: 1 target, 21 features, identificadores como metas.



Pipeline

Flujo de widgets encadenado, reproducible de punta a punta.



Feature Engineering

ratio_monto_vs_limite

Gasto dividido por el límite de su política. Un valor mayor a 1 implica violación de política.


t = 52,9

ratio_monto_vs_historico

Gasto dividido por el histórico del empleado. Mide el desvío respecto de su patrón habitual.

t = 40,4

Juntas concentran el 71% de la importancia del modelo ganador.




Balanceo de Clases (SMOTE)

- SMOTE crea casos sintéticos interpolando entre vecinos reales ($K = 5$).
- No duplica filas: evita el sobreajuste del oversampling simple.
- Balanceo parcial 60/40, no 50/50: menos sobre-muestreo.
- Preserva el desbalance real que el modelo encontrará en producción.

Se generaron 2.020 casos sintéticos (15.000 $\rightarrow$ 17.020 filas).

Distribución antes y después



Modelos Evaluados



Logistic Regression

Modelo lineal e interpretable. Sirve como línea base de referencia.



Random Forest

Ensamble de árboles en paralelo. Captura no linealidades e interacciones.



Gradient Boosting

Ensamble secuencial. El más potente para datos tabulares estructurados.

MODELO GANADOR

Metodología de Evaluación



Split 80 / 20 (Data Sampler)

Estratificado y replicable: 13.616 de entrenamiento, 3.404 de prueba.



Test and Score

Evaluación de los tres modelos sobre el mismo conjunto de prueba.

Métricas utilizadas

- AUC — capacidad de discriminación general.
- Recall — cobertura sobre el fraude (métrica decisora).
- Precision — certeza de cada alerta generada.
- F1 — balance entre precisión y cobertura.

Por qué priorizamos Recall

Falso Negativo: un fraude aprobado sin auditar.
Pérdida de dinero irrecuperable.

Falso Positivo: una revisión de más. Solo cuesta tiempo, recuperable.

Resultados Comparativos

Modelo	AUC	Recall	Precision	F1	MCC
Logistic Regression	0,805	0,562	0,751	0,643	0,468
Gradient Boosting	0,888	0,694	0,844	0,761	0,634
Random Forest	0,882	0,692	0,842	0,760	0,632

Gradient Boosting lidera en todas las métricas. Random Forest queda muy cerca; Logistic Regression queda atrás, lo que evidencia la naturaleza no lineal del problema.



Modelo Ganador: Gradient Boosting

0,888

AUC

0,694

Recall

0,844

Precision

0,761

F1

Justificación de la elección

- Mejor AUC, Recall, Precision, F1 y MCC entre los tres modelos.
- Captura el 69% de los fraudes con solo 16% de falsas alarmas.
- Random Forest es una alternativa válida; la diferencia es marginal.

Matriz de Confusión

Actual	Predicted		
	0	1	
	0	1	Σ
0	1867	175	2042
1	417	945	1362
Σ	2284	1120	3404

945 — Verdaderos Positivos

Fraudes detectados que pasan a revisión priorizada.

1.867 — Verdaderos Negativos

Legítimos correctamente aprobados, sin revisión.

175 — Falsos Positivos

Revisiones de más; costo de tiempo recuperable (16%).

417 — Falsos Negativos

Fraudes que escapan: el error más costoso (31%).

Impacto Operativo - Mejoras

3.404

rendiciones del período



1.120

alertas generadas (33%)



945

fraudes detectados

67%

menos revisión manual


69%

del fraude capturado

3×

más eficiente

Feature Importance



71%

de la importancia se concentra en los dos ratios creados en Feature Engineering.

El tiempo y la jerarquía del empleado tienen importancia nula.

Las dos variables derivadas superan a cualquier dato original del sistema: la prueba de que el Feature Engineering fue la pieza más valiosa del pipeline.

Conclusiones

- Modelo operativo: Gradient Boosting con AUC 0,888 y Recall 0,694.
- Captura el 69% del fraude con solo 16% de falsas alarmas.
- El Feature Engineering fue decisivo: 71% de la importancia del modelo.
- El comportamiento temporal y la jerarquía no son predictivos.

Respuesta a las hipótesis

H1

Confirmada — desvío del histórico (vía ratio).

H2

Confirmada — violación de política y proveedor.

H3

Refutada — el patrón temporal no informa.

Recomendaciones de Negocio

01



Cola priorizada

Calificar cada rendición y derivar a Auditoría solo las de alto riesgo (umbral 0,5).

02



Reglas duras

Auditoría obligatoria para todo gasto superior a \$300.000, sin pasar por el filtro.

03



Dato obligatorio

Volver obligatorio el campo de proveedor para eliminar la ambigüedad de 'Sin_dato'.



Próximos pasos: pipeline productivo en Python (SMOTE solo en train) · tuning de hiperparámetros · validación con múltiples particiones · SHAP para explicar caso por caso.

Muchas gracias

Benjamín Alonso · Joaquín Gelves · Simón Godino Ferrando · Simón Lawson · Augusto Díaz de Valdés ·
Justo Valente



¿Preguntas?